



# База данных Кластеров Ортологичных Групп и ее применение для биоинформатического анализа белков

**Дарья Владимировна Диброва**

**с.н.с. НИИ ФХБ, МГУ имени М.В. Ломоносова,  
доцент ФББ МГУ**

***17 сентября 2025 г.***

# 1. Кластеры Ортологичных Групп (КОГи)

# Если продукты генов похожи – это «один и тот же» белок?


3

**Гомологи:** гены, которые имеют **общее происхождение**


(= существовала предковая последовательность, в ходе эволюции которой возникли данные гены)

**Ортологи:** гены, которые разошлись вследствие **видообразования**

**Паралоги:** гены, которые разошлись вследствие **дупликации гена**



- КОГ (COG) – Кластер Ортологичных Групп (белков или их генов)
- Минимальный КОГ: 3 белка из трех геномов, которые друг для друга являются **взаимными лучшими находками по сходству**
- КОГ увеличивается за счет объединения таких треугольников **с общей стороной** (и потом иных эмпирических и ручных процедур)




Tatusov, Koonin, Lipman. A Genomic Perspective on Protein Families. *Science*, 1997.

Kristensen *et al.* A low-polynomial algorithm for assembling clusters of orthologous groups from intergenomic symmetric best matches. *Bioinformatics*, 2010.

**Examples of COGs.** Solid lines show symmetrical BeTs. Broken lines show asymmetrical BeTs, with color corresponding to the species for which the BeT is observed. <...>


**(B)** A simple COG with two yeast paralogs. Origin of the proteins: IleS, *E. coli*; HIN0378, *H. influenzae*; MG345, *M. genitalium*; MP322, *M. pneumoniae*; MJ0947, *M. jannaschii*; and YBL076c and YPL040c, *S. cerevisiae*.



Note the adjacent triangles with a common side, for example, IleS-MG345-MJ0947 and slI1362-MG345-MJ1362. YPL040c is the yeast mitochondrial isoleucyl-tRNA synthetase; the bacterial orthologs and that from *M. jannaschii* are the BeTs for this yeast protein, but the reverse is true only of the bacterial proteins (symmetrical BeTs). Conversely, for YBL076c, which is the yeast cytoplasmic isoleucyl-tRNA synthetase, the *M. jannaschii* ortholog is a symmetrical BeT, whereas the bacterial BeTs are asymmetrical.

**Examples of COGs.** Solid lines show symmetrical BeTs. Broken lines show asymmetrical BeTs, with color corresponding to the species for which the BeT is observed. <...>

**(C)** A complex COG with multiple paralogs. Origin of the proteins: RpoH, RpoS, RpoD, and FliA, *E. coli*; HIN1403 and HIN1655, *H. influenzae*; MG249, *M. genitalium*; MP485, *M. pneumoniae*; slI0184, slI0306, slr0653, slI1689, slI2012, and slr1564, *Synechocystis sp.*



**RpoD**, **HIN1655**, **slr0653**, and **MG249** are major sigma factors ( $\sigma 70$ ), whose function is universal in bacteria; note the fully symmetrical relationships between these proteins. The other proteins are specialized sigma factors whose radiation from the ancestral family apparently was accompanied by modification of the function and involved accelerated evolution; note the asymmetrical BeTs.





Рисунок из: Kristensen *et al.* A low-polynomial algorithm for assembling clusters of orthologous groups from intergenomic symmetric best matches. *Bioinformatics*, 2010.

- При кажущейся простоте, построение биологически осмысленных КОГов совершенно нетривиальная задача.
- Нужно понимать, с каким КОГом мы имеем дело – с «простым» или «сложным».
- КОГ – не «кластер ортологов», но «кластер ортологичных групп» (т.е. в нем могут быть паралоги, но относительно близкие).
- На практике к КОГу относят не весь белок, а его часть, что немного приближает КОГи к «доменам».

## 2. База данных КОГов

| Год выхода статьи | Число геномов |              |            |            | Число КОГов  | Число белков     | Покрытие протеомов |
|-------------------|---------------|--------------|------------|------------|--------------|------------------|--------------------|
|                   | Всего         | Bacteria     | Archaea    | Eukaryotes |              |                  |                    |
| <b>1997</b>       | 7             | 5            | 1          | 1          | 720          | 6 646            | 37 %               |
| <b>2003</b>       | 66            | 50           | 13         | 3          | 4 873        | 138 458          | 75 %               |
| <b>2014</b>       | 711           | 628          | 83         | 0          | 4 631        | 1 837 823        | 50–80 %            |
| <b>2021</b>       | 1 309         | 1 187        | 122        | 0          | 4 877        | 3 213 255        | 73.5 %             |
| <b>2025</b>       | <b>2 296</b>  | <b>2 103</b> | <b>193</b> | <b>0</b>   | <b>4 981</b> | <b>5 627 389</b> | <b>72.5 %</b>      |

Tatusov, Koonin, Lipman. A Genomic Perspective on Protein Families. *Science*, **1997**. [4530 цитирований на 2025 г. по данным Google Scholar]



Tatusov *et al.* The COG database: an updated version includes eukaryotes. *BMC Bioinformatics*, **2003**. [5154 цитирования]

Galperin, Makarova, Wolf and Koonin. Expanded microbial genome coverage and improved protein family annotation in the COG database. *NAR*, **2014**. [1642 цитирования]

Galperin *et al.* COG database update: focus on microbial diversity, model organisms, and widespread pathogens. *NAR*, **2021**. [802 цитирования]

**Galperin *et al.* COG database update 2024. *NAR*, **2025**. [31 цитирование]**

<https://www.ncbi.nlm.nih.gov/research/cog/>

## C - COG1290 - Cytochrome b subunit of the bc complex

COG symbol: QcrB/PetB  
PDB entry: 1VF5

### Basic Stats

Organisms: 1245/2296  
Genes: 1616/5994451  
Proteins: 1616/5628142  
Median Protein Length: 406.04

### Taxonomy Categories

Click on table rows for more information

#### ARCHAEA

-  ASGARDARCHAEOTA [0/8 organisms 0 genes]
-  CRENARCHAEOTA [14/29 organisms 27 genes]
-  EURYARCHAEOTA [41/103 organisms 101 genes]
-  NITROSOSPHEROTA [12/13 organisms 12 genes]
-  THERMOPLASMATOTA [8/17 organisms 12 genes]
-  OTHER\_ARCHAEA [4/23 organisms 4 genes]

#### BACTERIA

-  ACIDOBACTERIOTA [9/16 organisms 14 genes]



### Аннотация:

- название;
- отнесение к функциональной группе;
- отнесение к метаболическому пути;
- ссылки: PDB, статьи, имя гена.



### Список белков:

- разбитый по таксономическим группам;
- паттерн встречаемости в разных геномах.
- последовательности белков.



Модель для поиска  
новых членов КОГа

### **3. Наши инструменты для работы с КОГами и белками вообще**

## Белки из набора геномов

$n$  белков

$m$  белков

Отнесены к  
какому-то КОГу


Не отнесены  
ни к одному КОГу

профильная НММ для COGxxxx

Dibrova D.V., Rykov S.Y. COGcollator 2.0: an improved web server for analysis of distant relationships between homologous protein families. *BGRS Abstracts*, Novosibirsk: ICG SB RAS, 2024. P. 60-62

(построены нами путем  
большой работы)

| Ранг | Вес   | Белок    | КОГи             |
|------|-------|----------|------------------|
| 1    | 500.1 | ecoli_1  | COGxxxx          |
| 2    | 487.0 | therma_2 | N/A              |
| 3    | 450.2 | bacsu_3  | COGxxxx          |
| 4    | 250.1 | therma_3 | COGyyyy          |
| 5    | 210.8 | therma_4 | COGyyyy, COGtttt |




# COGcollator 2.0: новый веб-сервер

14

<https://boabio.belozersky.msu.ru/COGcollator>


- **Две базы данных:** профили HMMs для КОГов и домены Pfam.
- **Интерактивный:** оба графика можно приближать, получать белки.
- **Два порога сходства.**
- **Фильтрация аннотаций,** которые не перекрываются с находками.



Наш набор профилей HMM для КОГов может быть использован для обнаружения участков белков, которые гомологичны известным КОГам

**COG0859**  
(NuoC)

**COG0649**  
(NuoD)



В данном случае в двух нижних белках наблюдается «сшивка» (fusion) между двумя КОГаами

Наш инструмент **Domain Analyser** показывает находки по КОГам или доменам Pfam в любых белках

<https://boabio.belozersky.msu.ru/DomainAnalyser>

 Domain Analyser 2.0: a tool for searching and visualising protein domains

Mode: FASTA 

1. Run hmmscan: done!  Download .domtblout

2. Run domain\_assigner: done!  Download .domains

3. Visualization  Download as SVG\*

X-axis size\*\*: 602 aa Set max Y-axis element height\*\*: 30 px Set Default Scheme only: ☐


Coordinates in protein\*\*: ☒ Coordinates in HMM\*\*: ☐ Show hit measure: None  Show domain ID\*\*: ☒

\* The appearance of the SVG image may not match the visualisation in the histogram below.  
\*\* These parameters are NOT taken into account while generating histogram SVG.

| Color                                                                              | Domain  | ## | Description                                            | Alignment<br>(none <input type="radio"/> ) |
|------------------------------------------------------------------------------------|---------|----|--------------------------------------------------------|--------------------------------------------|
|  | COG0649 | 6  | NADH:ubiquinone oxidoreductase 49 kD subunit (chain D) | <input checked="" type="radio"/>           |
|  | COG0852 | 2  | NADH:ubiquinone oxidoreductase 27 kD subunit (chain C) | <input type="radio"/>                      |

Domain colors Apply Reset

COG0649 #0000ff  
COG0852 #00ff00




| Protein ID    | COG0852 Count | COG0852 Position | COG0649 Count | COG0649 Position |
|---------------|---------------|------------------|---------------|------------------|
| DP_RS06680    | 0             | 0                | 11            | 372              |
| CHU_RS02545   | 0             | 0                | 18            | 392              |
| DESOR_RS20035 | 0             | 0                | 5             | 366              |
| AL705_RS07395 | 0             | 0                | 48            | 456              |
| THAL_RS06180  | 24            | 150              | 194           | 572              |
| HYDTH_RS02095 | 11            | 151              | 194           | 572              |

- На вход — набор белков в FASTA-формате.
- Много параметров для предсказания доменов.
- Интерактивный.
- Все файлы и итоговый рисунок — в векторном формате.

# Чем дополнить филогенетическое дерево?

17



# Гомолог Кеар1 с циклической перестановкой

18



The tree is colored according to taxonomy:




1) Цветовой код таксономии.

2) Доменная структура белков.

Кеар1 человека



Pfam domains:



Shilovsky G.A., Dibrova D.V. Regulation of Cell Proliferation and Nrf2-Mediated Antioxidant Defense: Conservation of Keap1 Cysteines and Nrf2 Binding Site in the Context of the Evolution of KLHL Family. *Life* 13(4): 1045, 2023.

- КОГи – отличный инструмент для классификации и анализа белков прокариот.
- Работу с конкретным КОГом имеет смысл начинать с поиска родственных белков через **COGcollator** (заодно можно найти эукариотические гомологи).
- Для визуализации доменов Pfam или находок КОГов в наборе последовательностей белков можно использовать **DomainAnalyser**.
- Очень поможет в работе умение работать с векторной графикой (напр. **Inkscape**).
- Для анализа геномного окружения белков можно использовать наш инструмент **pyCOGNAT** (про него в следующий раз).

- В течение осеннего семестра у нас будет проходить «журнальный клуб»: каждый **студент 2 и 3 курсов** сделает небольшой доклад с анализом статьи, связанной с тематикой его курсовой работы (доклад на 15-20 минут).
- Этот анализ можно будет положить потом в основу лит. обзорной части доклада и/или текста.
- После рассказа статьи нужно будет сказать несколько слов и о том, в чем состоит тема работы студента.
- **Дипломники** сделают рассказ в формате «предзащиты», отрепетируют ее таким образом на нашем семинаре.