



«Продвинутые» опции инструментов COGcollator и Domain Analyser. База данных КОГов

Дарья Владимировна Диброва

**с.н.с. НИИ ФХБ, МГУ имени М.В. Ломоносова,
доцент ФББ МГУ**

8 октября 2025 г.


1. «Продвинутые» опции COGcollator

COGcollator 2.0: новый веб-сервер



3

<https://boabio.belozersky.msu.ru/COGcollator>

- **Две базы данных:** профили HMMs для КОГов и домены Pfam.
- **Интерактивный:** оба графика можно приближать, получать белки.
- **Два порога сходства.**
- **Фильтрация аннотаций,** которые не перекрываются с находками.



(1) MMC1_RS13890
(2) MY04_RS09770
(3) TFU_RS03590




COG1112

(Filter: **None**)


- Если белок на графике COGcollator отнесен к нескольким КОГам, они по умолчанию показаны все.
- Но отнесения к КОГам, которые не перекрываются по координатам с находкой данного профиля HMM, можно отфильтровать.

Фильтрация не идеальна, но помогает в анализе
типично мульти-КОГовых белков



COG1112

(Filter: **None**)



COG1112

(Filter: **Yes**)

2. «Продвинутые» опции Domain Analyser

Наш инструмент **DomainAnalyser** показывает находки по КОГам или доменам Pfam в любых белках

<https://boabio.belozersky.msu.ru/DomainAnalyser>

Domain Analyser 2.0: инструмент для поиска и визуализации белковых доменов

Как получать данные: FASTA

1. Запуск hmmscan: [gomovol](#)   Скачать .domtblout

2. Запуск domain_annotator: [gomovol](#)   Скачать .domains

3. Визуализация  Скачать SVG*

Размер оси X**: 814 а.о. Высота элемента оси Y**: 26 px Только схема: ☐

Координаты в белке**: ☒ Координаты в HMM**: ☐ Показывать меру находки: Нет Показывать ID домена**: ☒

* Внешний вид SVG-изображения может не совпадать с визуализацией в гистограмме ниже.
** Данные параметры НЕ учитываются при генерации SVG на основе гистограммы.

Цвет	Домен	##	Описание	Выводить (нет ☐)	Цвета доменов
	COG0649	7	NADH:ubiquinone oxidoreductase 49 kD subunit (chain D)	☒	COG0649 #0FEBD7
	COG0852	3	NADH:ubiquinone oxidoreductase 27 kD subunit (chain C)	☐	COG0852 #37ABC8
	COG0377	2	NADH:ubiquinone oxidoreductase 20 kD subunit (chain B) or related Fe-S oxidoreductase	☐	COG0377 #008080

АFLV_RS14035 4 COG0649 365

RAM_RS02660 55 COG0649 460

FQ762_RS23620 32 COG0649 440

F1C76_05885 38 COG0649 440

A11Q_RS09825 30 COG0852 155 178 COG0649 565

GMET_RS00770 4 COG0377 159 228 COG0852 378 403 COG0649 791

dnI_RS11635 12 COG0377 158 226 COG0852 381 406 COG0649 795

- На вход – набор белков в FASTA-формате.
- Много параметров для предсказания доменов.
- Интерактивный.
- Можно скачать промежуточные файлы в текстовом виде.
- Схема доменной структуры – в векторном формате.

Порог перекрытия: фильтрация находок

8



2. Запуск domain_assigner: [zomovo!](#)

Скачать .domains

Тип E-value: Порог E-value: Порог перекрытия (%): Объединять: ☒ Макс. дистанция: Макс. перекрытие HMM (%):

Пересчитать

- Если «отпечатки», КОГов **перекрываются** более чем на % длины каждого из них – оставить самый лучший



При пороге перекрытия 100% фильтрация отключена

9

2. Запуск domain_assigner: [зотово!](#)

[Скачать .domains](#)

Тип E-value: ? Порог E-value: ? Порог перекрытия (%): ?
Объединять: ☒ ? Макс. дистанция: ? Макс. перекрытие HMM (%): ?

Пересчитать



COG0649
RAM_RS02660 (Длина: 460)

E-value: 2.2e-162
Вес: 538.5

Координаты
-- в HMM: [16, 406]
-- в белке: [55, 460]

COG0649:
NuoD

COG3261
RAM_RS02660 (Длина: 460)

E-value: 1.7e-83
Вес: 278.7

Координаты
-- в HMM: [4, 360]
-- в белке: [60, 460]

COG3261: Ni,Fe-
hydrogenase III
large subunit)

COG3259
RAM_RS02660 (Длина: 460)

E-value: 0.0000033
Вес: 24.6

Координаты
-- в HMM: [16, 188]
-- в белке: [73, 235]

COG3259: Coenzyme
F₄₂₀-reducing
hydrogenase, alpha
subunit

При пороге перекрытия 5% фильтрация строгая

10

2. Запуск domain_assigner: [zomovo!](#) ▾

[Скачать .domains](#)

Тип E-value: ? Порог E-value: ? Порог перекрытия (%): ?
Объединять: ☒ ? Макс. дистанция: ? Макс. перекрытие HMM (%): ?

Пересчитать



■ COG0649

RAM_RS02660 (Длина: 460)

E-value: 2.2e-162

Вес: 538.5

Координаты

-- в HMM: [16, 406]

-- в белке: [55, 460]

COG0649:
NuoD


- Для большинства обычных задач порог фильтрации «по умолчанию» (перекрытие от 5% длины каждого домена) оптимален.
- В сложных случаях может быть полезно выбрать другие значения: например, чтобы увидеть действительно ли находки КОГов сильно отличаются.

Когда нужен ручной анализ

11





COG5016 Pyruvate/oxaloacetate carboxyltransferase



COG4770 Acetyl/propionyl-CoA carboxylase, alpha subunit




COG0511 Biotin carboxyl carrier protein



- Гомологи глутаконил-КоА декарбоксилазы, оксалаатдекарбоксилазы, обычно содержат фьюжн между COG5016 (субъединицей α) и биотин-связывающей субъединицей γ .
- Но к какому КОГУ относится субъединица γ : COG4770 или COG0511?..

Источник схемы слева: Buckel W. Sodium ion-translocating decarboxylases. *Biochimica et Biophysica Acta*, 2001 (цвета добавлены к источнику)

- Порог перекрытия 100% (фильтрация выключена):





- Порог перекрытия 5% (строгая фильтрация включена):





Домены в белках по КОГам и по Pfam

13



VS.



2. Запуск domain_assigner: [zomovo!](#) ▾

Скачать .domains

Тип E-value: ? Порог E-value: ? Порог перекрытия (%): ?



Объединять: ☒ ?

Макс. дистанция: ?

Макс. перекрытие HMM (%): ?

Пересчитать

- Последовательно идущие находки одного и того же домена могут быть ошибочно «разорванной» находкой!



Пример применения опции объединения


15




COG5016 Pyruvate/oxaloacetate carboxyltransferase

Тип E-value: ? Порог E-value: ? Порог перекрытия (%): ?


Объединять: ☒ ? Макс. дистанция: ? Макс. перекрытие HMM (%): ?



! В режиме «только схема» это приведет к артефакту: якобы дубликации домена!



! Выставим «макс. дистанцию» = 60 а.о.:



3. Визуализация ▾

[Скачать SVG*](#)

Размер оси X**: а.о. Высота элемента оси Y**: px Только схема: ☐

Координаты в белке**: ☒ Координаты в HMM**: ☐ Показывать меру находки: Показывать ID домена**: ☒

* Внешний вид SVG-изображения может не совпадать с визуализацией в гистограмме ниже.

** Данные параметры НЕ учитываются при генерации SVG на основе гистограммы.

Цвет	Домен	##	Описание	Выровнять (нет ☐)	Цвета доменов	Применить	Сброс
	COG0649	7	NADH:ubiquinone oxidoreductase 49 kD subunit (chain D)	☒	COG0649 #0FEBD7		
	COG0852	3	NADH:ubiquinone oxidoreductase 27 kD subunit (chain C)	☐	COG0852 #37ABC8		
	COG0377	2	NADH:ubiquinone oxidoreductase 20 kD subunit (chain B) or related Fe-S oxidoreductase	☐	COG0377 #008080		

- Размер картинки можно настраивать.
- Домены показываются по их координатам или просто по порядку следования.
- Цвета доменов можно выбрать вручную или задать текстом.
- Разная информация о находке может быть показана.
- Результат можно скачать в виде векторной картинки в SVG-формате.

3. Устройство базы данных КОГов

<https://www.ncbi.nlm.nih.gov/research/cog>

Updated: August, 2025

Database of Clusters of Orthologous Genes (COGs)

COG DATABASE COG CATEGORIES PATHWAYS WEB SERVICES **COG PROJECT** CONTACT

COGs stand for Clusters of Orthologous Genes. The database was initially created in 1997 (Tatusov et al., PMID: 9381173) followed by several updates, most recently in 2024 (Galperin et al., PMID: 39494517). The current update includes genomes from 2,103 bacterial and 193 archaeal species, of which 2,232 represent complete genomes in RefSeq and 64 are at the "Chromosome" level. The new features include updated COG annotations with corresponding references and PDB links, where available, and >100 new COGs for proteins involved in protein secretion pathways and those with unknown functions. **The latest COG files with incremental updates can be found in the COG2024 folder on the NCBI's FTP site.**

Search

Search by:

COG Definition (COG0105 or just the number 105)
Any word in the COG name (polymerase)
Taxonomic Category (Mollicutes)
Organism name (Aciduliprofundum_boonei_T469)
Pathway (Arginine biosynthesis)
Assembly (GCA_000091165.1)
Protein name: (prot:WP_011012300.1)
Gene Tag: (gene_tag:Haur_1857)

Statistics

COGs	Genomic loci	Taxonomic Categories	Organisms	Protein IDs	COG symbols
5,061	6,266,336	42	2,296	5,872,258	4,106

! Нам имеет смысл работать с текстовыми файлами, в которых сохранена информация о КОГах

- Readme.COG2024.txt ← Хорошее, годное описание всего
- cog-24.cog.csv ← Основной файл: отнесение белков к КОГам
- cog-24.def.tab ← Определение КОГов: название, ссылки и пр.
- cog-24.fun.tab ← Функциональные категории (высокого ранга)
- cog-24.mapping.tab ← Характерные белки в UniProt
- cog-24.org.csv ← Список организмов, сборок, taxid
- cog-24.pathways.tab ← «Метаболические пути» и КОГи
- cog-24.tax.csv ← Таксономия
- COGorg24.faa ← Последовательности

В файле лежат последовательности из 2296 организмов (покрытых текущей версией базы данных КОГов), в том числе к КОГам не отнесенные, **в формате FASTA.**

```
>YP_002344626.1 peptidase M23 family protein [Campylobacter jejuni subsp. jejuni NCTC 11168 = ATCC 700819]
MKALWILLSLTWLFGAQNLELIKQALFLELDKKDFLSLKNNDKNIPTFAHPKNQEKILAI FSLPYKNPPQNTKLI AFY
KDKKEE I FIKTLEGNYKSEKLQIENKKIFPPKTIQERITKELKEANAIYSSYTPKALFNGAFNIPLNSFITSDFGKARTF
NEKVASYHSGTDFRATTGTPIYAANS GVVKIAKDRYFAGNSVVIDHGFGIYSQYYHLSKIDVKIGQKIKKGELIGLSGAT
GRVSGPHLHFGILAGGKQVDPLDFVSKFN AIFQ
```

! Проблема: некоторые (многие) белки записаны под неуникальными идентификаторами `protein_id...`

```
>WP_004937080.1 MULTISPECIES: 30S ribosomal protein S9 [Yersiniaceae]
MAENQYYGTGRRKSSAARVFIKPGNGNIVINQRSLEQYFGRETARMVVRQPLELVDMMVGKLDLYITVKGGGISGQAGAIR
HGITRALMEYDETLRSELRKAGFVTRDARQVERKKVGLRKARRRPQFSKR
```

Содержимое файла cog-24.cog.csv

21

В файле лежит отнесение белков к КОГам в формате CSV
(**comma**-separated values)

```
...  
AWC35_RS15260,GCF_002291425.1,WP_004937080.1,130,1-130,130,COG0103,COG0103,0,174.0,3.78e-57,130,1-130  
SMDB11_RS17780,GCF_000513215.1,WP_004937080.1,130,1-130,130,COG0103,COG0103,0,174.0,3.78e-57,130,1-130  
...
```

1. Gene ID (GenBank or ad hoc) ← Обычно – /locus_tag из геномной записи
 2. NCBI Assembly ID ← Сборка
 3. Protein ID (GenBank if conforms to [A-Za-z0-9_]+\.[0-9]+ regex; ad hoc otherwise) ← /protein_id
 4. Protein length ← Длина белка
 5. COG footprint coordinates on the protein. "201-400" means "from position 201 to position 400"; "1-100=201-300" indicates a segmented footprint, 1-100 AND 201-300 ← «Отпечаток» КОГа на белке, координаты находки КОГа
 6. Length of the COG footprint on the proteins
 7. COG ID ← Идентификатор КОГа
 8. Reseved (currently shows COG ID)
 9. COG membership class (0: footprint covers most of the protein and most of the COG profile; 1: footprint covers most of the COG profile and part of the protein; 2: footprint covers most of the protein and part of the COG profile; 3: partial match on both protein and COG profile) ← Качество находки
 10. PSI-BLAST bit score for the match between the protein and COG profile
 11. PSI-BLAST e-value for the match between the protein and COG profile
 12. COG profile length
 13. Protein footprint coordinates on the COG profile
- Числовые характеристики находки (по данным PSI-BLAST)

- Скачиваем себе все файлы базы данных КОГов с FTP и работаем с ними.
- Написать скрипт, который будет извлекать из файла с базой данных КОГов (`cog-24.cog.csv`) и файла с описанием организмов (`cog-24.org.csv`) данные о белках, отнесенных к заданному КОГу, и выписывать их в виде таблицы со колонками: `protein_id`, `locus_tag`, сборка генома, название организма, `taxid` организма.
- Скрипт должен получать на вход: идентификатор нужного КОГа, имя файла с базой данных КОГов, имя файла с данными об организмах.