



Применение инструментов COGcollator, Domain Analyser и ruCOGNAT для филогеномного анализа белков

Дарья Владимировна Диброва


**с.н.с. НИИ ФХБ, МГУ имени М.В. Ломоносова,
доцент ФББ МГУ**

21 октября 2025 г.


1. Case study: пример применения наших инструментов к белковому комплексу

Типичный NDH-1 с 14 субъединицами

3




PDB: **8E9G** из *Mycobacterium smegmatis* MC2 155



n-сторона

МЕМБРАНА


p-сторона



Доменная структура субъединиц по КОГам


4

Наш инструмент DomainAnalyser показывает, какие участки белка соответствуют какому КОГу:



COGcollator показывает, что COG0650 является паралогом COG1005

5





RCSB **PDB**
PROTEIN DATA BANK

«Изученные белки» можно взять из SwissProt и/или PDB:

1) Быстрый способ:


- a) поискать в BLAST все значимые находки для любого белка из Вашей выборки **в базе данных SwissProt и/или в базе данных PDB**;
- b) обязательно: проверить, к каким КОГам относит эти белки DomainAnalyser и пр., убрать те белки, которые не относятся к нужным КОГам.

2) Напрямую:

- 1) скачать базу данных SwissProt и/или PDB целиком;
- 2) поискать в ней через BLAST и/или HMMer.

Построим филогенетическое дерево NuoH и его гомологов по данным обоих КОГов

7




Визуализация геномного окружения

8

Наш инструмент **pyCOGNAT** показывает находки доменов (КОГи или домены Pfam) в геномном окружении заданных генов


<https://github.com/udavdasha/pyCOGNAT>



[..DONE..] Obtained 31 lines of drawable objects


Геномное окружение паралогов NuoH

9




Геномное окружение паралогов NuoH

10




Геномное окружение паралогов NuoH

11




Геномное окружение паралога NuoH

12



2. Откуда взять актуальные данные таксономии?

- Таксономия (в биологии): раздел биологической систематики, решающий задачу классификации живых организмов, отнесение их к тому или иному **таксону**.
- Таксономия предполагает древовидную структуру организации данных.
- Для отнесения к тому или иному таксону используется большое количество **таксономических маркеров**
(например, для эукариот – последовательность цитохрома *b* (из митохондриального генома), для прокариот – набор рибосомальных белков, или последовательность 16S рРНК)



Источник рисунка: https://ru.wikipedia.org/wiki/Биологическая_систематика

См. также: <http://tolweb.org/tree/>

NCBI Taxonomy: полезные ссылки

15

<https://www.ncbi.nlm.nih.gov/taxonomy>

**National Library of Medicine**
National Center for Biotechnology Information

Log in

Taxonomy

Taxonomy

Search

Limits Advanced

Help



Taxonomy

The Taxonomy Database is a curated classification and nomenclature for all of the organisms in the public sequence databases. This currently represents about 10% of the described species of life on the planet.

Using Taxonomy

- [Quick Start Guide](#)
- [FAQ](#)
- [Handbook](#)
- [Taxonomy FTP](#)
- [Important Update: Phyla Changing](#)
- [Important Update: New Flu species Names](#)

Taxonomy Tools

- [Browser](#)
- [Common Tree](#)
- [Statistics](#)
- [Name/ID Status](#)
- [Genetic Codes](#)
- [Linking to Taxonomy](#)
- [Extinct Organisms](#)

Other Resources

- [GenBank](#)
- [LinkOut](#)
- [E-Utilities](#)
- [Batch Entrez](#)
- [INSDC](#)

Disclaimer: The NCBI taxonomy database is not an authoritative source for nomenclature or classification - please consult the relevant scientific literature for the most reliable information.

Интерфейс Name/ID Status: имена

16

Taxonomy name/id Status Report Page

Please enter a list of names or tax_id(s):

Escherichia coli
Escherichia coli
Bacillus sp.

or enter a path to the data file:

Выберите файл Файл не выбран

☐ full taxid lineage ☐ exclude common names

Show on screen

Save in file


По названию вида (или любого таксона) можно получить:

1. Идентификатор таксономии (**taxid**);
2. Список **taxid** для всех вышестоящих таксонов в обратном порядке (от частного к общему).



code	name	preferred name	taxid
1	Escherichia coli		562
3	Escherichia coli		
1	Bacillus sp.	Bacillus sp. (in: firmicutes)	1409

[Back to the initial page](#)




code	name	preferred name	lineage
1	Escherichia coli		562 561 543 91347 1236 1224 2 131567
3	Escherichia coli		
1	Bacillus sp.	Bacillus sp. (in: firmicutes)	1409 185979 1386 186817 1385 91061 1239 1783272 2 131567

Taxonomy name/id Status Report Page

Please enter a list of names or tax_id(s):

562
561
543
91347
1236
1224
2
131567



code	taxid	primary taxid	taxname
1	562	562	Escherichia coli
1	561	561	Escherichia
1	543	543	Enterobacteriaceae
1	91347	91347	Enterobacterales
1	1236	1236	Gammaproteobacteria
1	1224	1224	Pseudomonadota
1	2	2	Bacteria
1	131567	131567	cellular organisms

or enter a path to the data file:

Выберите файл Файл не выбран

☐ full taxid lineage ☐ exclude common names

Show on screen

Save in file

По идентификатору таксономии
можно получить, соответственно,
его полное название

(больше информации, в том числе данные о разных
исторических названиях таксонов, можно получить из
файлов базы данных через FTP на сайте NCBI)

- Таксономия подвержена регулярному пересмотру:
 - Регулярно изменяются и уточняются названия конкретных видов;
 - Бывает что меняются даже названия более «глобальных» групп: из последнего – разделение и переименование группы протеобактерий.
- Нужно проверять периодически, не поменялась ли общепринятая таксономия!

Proteobacteria:

- α -proteobacteria
- β -proteobacteria
- γ -proteobacteria
- ...
- δ -proteobacteria
- ϵ -proteobacteria



Pseudomonadota:

- α -proteobacteria
- β -proteobacteria
- γ -proteobacteria
- ...



Desulfobacterota



Campylobacterota

Если любите программировать, можно скачать себе релиз NCBI Taxonomy на компьютер и написать собственный скрипт, который будет с ним работать.

Основной файл: **taxdmp.zip** или **taxdump.tar.gz**



`citations.dmp`

← Ссылки на статьи

`delnodes.dmp`

`division.dmp`

`gc.prt`

`gencode.dmp`

`images.dmp`

← Ссылки на картинки с разными видами!

`merged.dmp`

names.dmp

← Соотнесение **taxid** и латинского названия

nodes.dmp

← Граф таксономии

`readme.txt`

← !

taxid



```
<...>
1299 | Deinococcus radiidurans | | equivalent name |
1299 | Deinococcus radiodurans | | scientific name |
1299 | "Micrococcus radiodurans" Raj et al. 1960 | | authority |
1299 | Micrococcus radiodurans | | synonym |
<...>
```

Интересные поля:

- `synonym`, `equivalent name` – как раньше мог называться организм;
- `authority` – кто его открыл и когда;
- `scientific name` – самое для нас важное, текущее научное название.

В файле `nodes.dmp` лежит граф таксономии: соотнесение между «ребенком» и «родителем»

21

	taxid		taxid		
	↓		↓		
Bacteria	<...>				
	2		131567		superkingdom <...>
Archaea	2157		131567		superkingdom <...>
	2759		131567		superkingdom <...>
Eukaryota	<...>				
	131567		1		no rank <...>
	<...>				


cellular organisms

! Читая этот граф, можно получить полную таксономию
для выбранного **taxid**

3. Appendix: программа AInalyser

Наш инструмент **Alnalyser** облегчает работу с набором белков (множественным выравниванием)

<https://github.com/udavdasha/alnalyser/>



Alnalyser (version 1.0.0)

dummy_project

Save project Load project Clear all

Check pending results

(1) Alignment parsing (2) Alignment purification (3) Write current state to log

Domain ID	Occurrence	Domain description
COG1290	9 (100.0)	Cytochrome b subunit of
COG2857	3 (33.3)	Cytochrome c1
COG2993	1 (11.1)	Cbb3-type cytochrome ox

Print external logs

Random colors Open domain colors panel

[...READY...]

Input Parsing Purification Features Project log Format converter

Insert multiple alignment or generate it from the left panel (9 sequences): Check input

Insert unaligned sequences (9 sequences): Align now! Insert BLOCKS & SITE maxiters 2 gapopen gapextend Filter identical

```
>CJA_2784|Cellvibrio_japonicus_Ueda107
-----MNNLVGLWQVVDKRLPVQRAWDTHMGKYYAPKNFNFWYFFGVLSLLVLVNQLVT
GIWLTMSFVPSSEG-----AFASVEYIMRDVVDYGIIRYMHSTGASAFFVUVYL
HMFGRGMYGSYKAPRELWVIFGMVIVLVMAEAFMGVYLPWGQMSYWGACQVIVSLFGAIP
VIGEDLVQWIRGDYLSIG-ITLNRFFALHVVVALPIVLLALVVMHILALHEVGSNNPDGVE
IKKNKD-----ENGIPRDGVPPHFFYTVHDLVGVTVFLFAFCFVI--FFPEMGGFFLE
YANFEEANNLKTPTIAPVWYFTFPYAVLRAVLIQI---ELGPLVLTAKLLGFIAMGAAI
ALLFVLPLWDRSKVKSMRYGRHPIRIMLITFAAMFVVLGVGVKSPDGRITFLSQIATAF
YFAYFL-TMPVWTTTSPKATSKISVWLCGVFAVIFAWMGIDYLGINDIPVLLYILTFAL
AIIFAVLPKLATRDKDLVPSRTQDKPLKLLVFAGLALFIILTVP-----IKA
VAAEGAFACGSI PCDEMVPDLK-----NKESLQRCAGYFVNY-CMGCHSAKFSRYER
VADDLDIPHELAEQNLIFGDQRI-----GELMEIAMRPQNAKWNF-----G
VVPDLSLVARSRSPSEWLYTYLRNFYKDDTRPFGVNNRVFPNVGPHVLIGPQGLLECGA
GPKLNHHGALRNEVGQIEMDEHC-GALKPGKIKGSLSTEEFDQAVYDLVNFLEYVAEPV
AVKQQQIGYVWLGFVLVILFIFVYFLNREFWRDIH
>TERTU_3677|Teredinibacter_turnerae_T7901
-----MNNWLTGLWTVVDARLPVQRAWDTHMGKYYAPKNFNFWYFFGVLSLLVLVNQLLT
GIWLTMYNPSAEE-----AFASVEYIMRDVFPFGWIIIRYMHSTGASAFFIVVYL
HMFGRGMYGSYKAPRELWVIFGMVIVLVMAEAFMGVYLPWGQMSYWGACQVIVSLFGAIP
YVGEDLVQWIRGDYLSIG-ATLNRFFALHVVVALPIVLLALVVMHILALHEVGSNNPDGVE
IKKNKD-----ENGIPLDGVPPHFFYTVHDLVGVTVFLFAFCFVI--FFPEMGGFFLE
HANFEQANSKLTPEHIAVWYFTFPYAVLRAVLIQI---ELGPLVLTAKLLGFIAMGAAI
-----
```

```
>CJA_2784|Cellvibrio_japonicus_Ueda107
MNNLVGLWQVVDKRLPVQRAWDTHMGKYYAPKNFNFWYFFGVLSLLVLVNQLVTGIWLTMSFVPSSEGAFASVEYIMRDVVDYGIIRYMHSTGASAFFVUVYLHMFGRGMYGSYK
>S58_55710|Bradyrhizobium_oligotrophicum_S58
MSGPDSYQPSHPALKWFEQRLPIIGLVHSSFIAYPTPRNLNYWTFGAILSIMLGQVQIVTGIVILAMHYTPHADLAFKSVELIVRDVNYGWLRLNMHACGASMFFLAVYIHMFRGLY
>TERTU_3677|Teredinibacter_turnerae_T7901
MNNWLTGLWTVVDARLPVQRAWDTHMGKYYAPKNFNFWYFFGVLSLLVLVNQLLTGIWLTMYNPSAEEAFASVEYIMRDVFPFGWIIIRYMHSTGASAFFIVVYLHMFGRGLMYGSYF
>Desti_1891|Desulfomonile_tiedjei_DSM_6799
MNGNWIIRIRIGWEPYLRPFLFKKLPGGTGMATLGNLSVLLFVLLFTTGIVLAMYYNPSPKACQSIDYIMNEVPMGSILRGLHHWGAGAMVLVVFHLLATFFSGSYKAPRELTV
>TTA1930|Thermus_thermophilus_HB8
MYRWLDERDLRLGLYHKVLRKAFVPHHSFFLGEITLFAFVVLVLTGVFLTLNYPEISIREVLADGRTPVPAAYASVLYIDSPLFGAVIRSLHHWSAHVMIAAAFLHMLRILLSGAYF
>Oter_3544|Opitutus_terrae_PB90-1
MKRRIVSIWDWLDRLGLSALFGPSLKLHLPVPHDARWVYVFGSATLAAFIIVQIITGVALAFSYPVSSAAEYELSRFITDEAPLGSFMRGLHYFGASAMVLMIGAHMAQTFLFGAYKY
>Hoch_3893|Haliangium_ochraceum_DSM_14365
MKRVLDWDDRTGYRQVQVQHSLEDPVAGGASFAVYFGSVLTIFILLQMTGVGFVFLAMYYSPSATDAWASVAFIQDSVTMGWFIRGLHSYGASAMVIVSGLHLLQTGLYGAYKKPREM
>CYB_YEAST|Saccharomyces_cerevisiae_(strain_ATCC_204508/_S288c)
MAFRKSNVYLSLVNSYIIDSPPQSSINYWNMGSLGLCLVIQIVTGIFMAMHYSSNIELAFSSVEHIMRDVHNGYILRYLHANGASFFFMVFMHMAKGLYGSYSRSPVTLNW
>CYB_HUMAN|Homo_sapiens
MTPMKRTNPLMKLINHSFIDLTPSNISAWNFGSLGACILQITITGLFLAMHYSPPDASTAFSSIAHITRDVNYGWIIRYLHANGASFFFCFLFHIGRGLYGSFLYSETWNIG
```